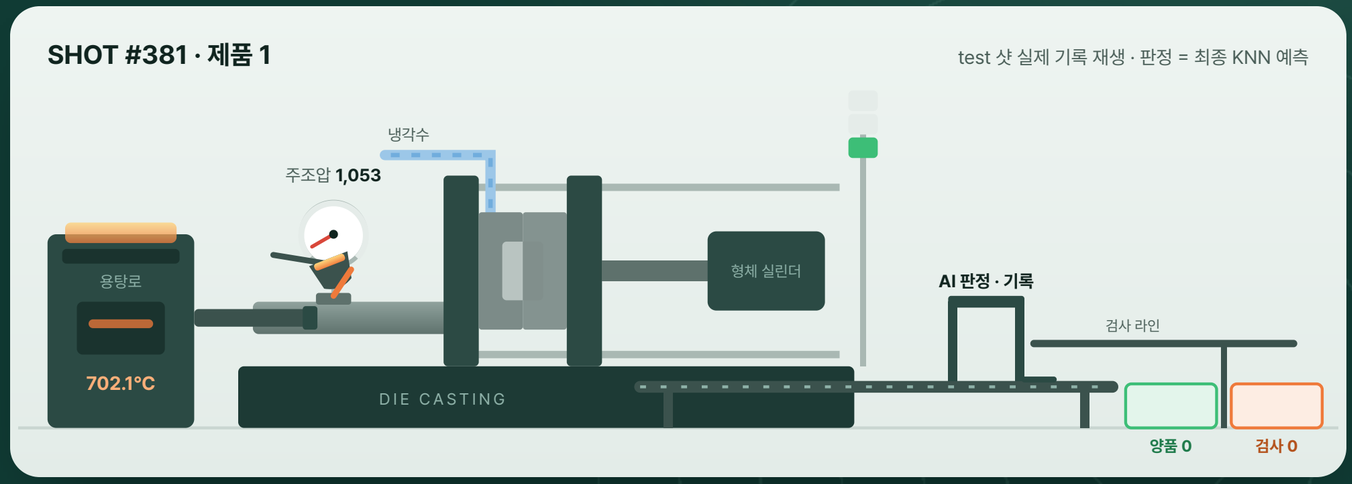
다이캐스팅 공정 데이터 · 불량유형 7종 예측

금형을 열기 전에, 불량을 알 수 있을까?

3조 · 강동하 · 구정희 · 이지수 · 이창우

① 주탕 ② 사출 ③ 냉각 ④ 형개 · 취출 ⑤ AI 판정 · 기록



1 주제 · 목표

샷마다 남는 공정 기록 21개로, 정상 포함 7가지를 예측한다

입력 · 샷 하나의 공정 기록

21개 값

용탕로 온도 · 사출 속도 · 주조압
냉각수 온도 · 압력 · 사이클 시간
공장 온도 · 습도 · 이형제 분사 …

제품 종류(Product_Type) 포함

출력 · 7가지 중 하나

- **Normal** 정상
- **Short_Shot** 미충전
- **Blow_Hole** 기공
- **Exfoliation** 박리
- **Stain** 얼룩
- **Deformation** 변형
- **기타불량** 기타

평가: **macro F1** — 7가지 F1을 똑같은 비중으로 평균.
정상만 많이 맞혀서는 오르지 않는다.

2 필요성

불량은 금형을 연 뒤에야 보인다 — 미리 알면 검사 순서와 공정 조건을 바꿀 수 있다

① 주탕	② 사출	③ 냉각	④ 형개 · 취출	⑤ 검사
쇳물 붓기	빠르게 밀어 넣기	식혀서 굳히기	금형 열고 꺼내기	불량은 **여기서 처음** 보인다

① ~④ 에서 남는 기록 21개로 ⑤ 전에 미리 판정

검사 우선순위

의심 샷부터 먼저 검사

후공정 손실 감소

불량이 다음 공정 · 출하로
넘어가기 전에 잡기

불량 조건 찾기

불량이 몰리는 공정 조건을
미리 손보기

3 데이터 소개 · 기초 통계

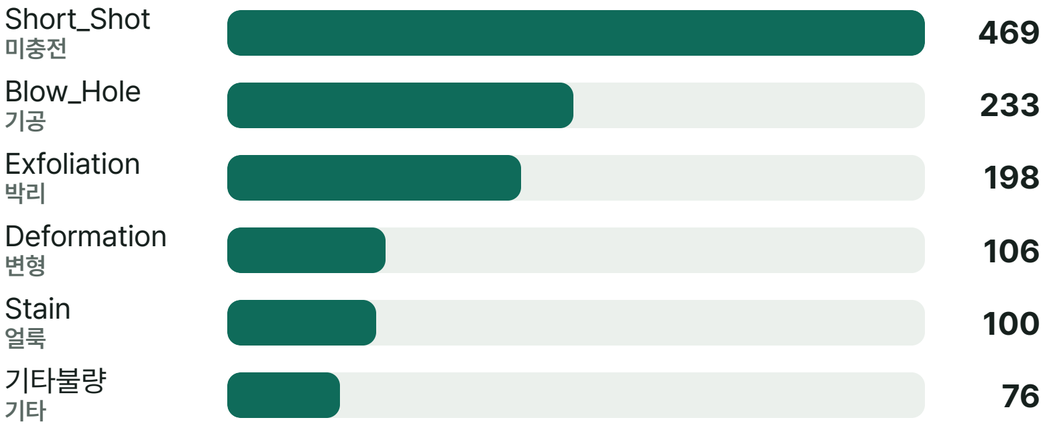
정답 있는 5,274샷 중 불량은 1,182샷 — 5개 중 1개꼴, 제품마다 불량 종류가 다르다

전체 7,535샷



public · private은 정답 없이 예측만 · 모든 분석과 검증은 train 안에서

train 유형 분포 · 정상 4,092샷 (77.6%) · 불량 1,182샷



가장 적은 기타불량은 1.4% — 클래스 불균형

제품별 샷 수 (train)

유형	제품 1 · 2,950샷	제품 2 · 2,324샷
Normal 정상	2,429	1,663
Short_Shot 미충전	161	308
Blow_Hole 기공	0	**233**
Exfoliation 박리	**198**	0
Deformation 변형	**106**	0
Stain 얼룩	2	**98**
기타불량 기타	54	22

제품 1을 먼저, 제품 2를 나중에 생산. 제품 1 불량률은 초반 37% → 후반 1%로 Spray_1_Time 설정과 함께 바뀜 → **Product_Type은 특징으로 유지**

4 데이터 문제 · 전처리

가장 큰 문제는 결측이 아니라 — 21개 값이 모두 같은 중복 기록 58.7%

결측

공장 온 · 습도 train 63행 · test 27행, 두 연속 구간

→ train 중앙값으로 채움 (방법별 차이 ±0.001)

상수 열

관리범위 Min/Max 8개 — 모든 행이 같은 값

→ 제외

식별 열

shot_id · id · Shot — 규칙상 특징 금지

→ 제외 (shot_id는 정렬에만)

이상값

0 값 6행 모두 정상 · 40초 넘는 사이클 15행 중 14행 정상

→ 불량 신호 아님, test에도 있어 유지

→ 특징 21개 열 11개 제외 · 결측은 중앙값 · 0~1 눈금 맞춤(MinMax) · 모두 train으로만 계산 · 행은 하나도 안 지움

중복 기록 · 동일 입력

3,097 / 5,274샷 (58.7%)

21개 값이 다른 train 샷과 **완전히 같음** · 모두 생산 순서상 바로 옆 행

라벨 충돌 값이 같은데 정답이 다른 **57개 그룹**

test에도 **57.7%**가 train에 같은 기록

이중 기록인지 연속 샷인지 구분 불가 → **행은 유지**하고, '처음 보는 샷' 성능을 **따로 검증** (5장)

5 검증 방법 · 평가지표

같은 KNN도 어떻게 나눠 시험하느냐에 따라 0.56 → 0.14

왜 정확도가 아니라 macro F1인가

'전부 정상'이라고만 답해도 정확도는 높다

정확도
77.6%

macro F1
0.125

macro F1 = 7가지 유형 F1의 단순 평균 → 정상만 맞혀서는 오르지 않고, 76건뿐인 기타불량도 똑같이 중요. 리더보드 채점 기준이라 모델 선택은 이 점수로

현장에서 함께 보는 두 숫자 (최종 KNN)

	무작위로 나눔	처음 보는 시기
불량 탐지율 재현율 실제 불량 중 잡은 것	1,182건 중 **600**	231건 중 **45**
경보 적중률 정밀도 경보 중 실제 불량	720건 중 **600**	200건 중 **45**

세 가지 분할 · 각각 무엇을 재나 (최종 KNN)

무작위로 나눔 · 5번 나눠 시험 × 3회 **0.562**



중복 기록이 학습 · 검증에 나뉨 → **리더보드와 비슷한 조건**

같은 기록끼리 묶어 나눔 · 5번 × 3회 **0.268**



값이 같은 샷을 한 묶음으로 → **처음 보는 샷** 성능

시간순 앞 80% → 뒤 20% **0.138**

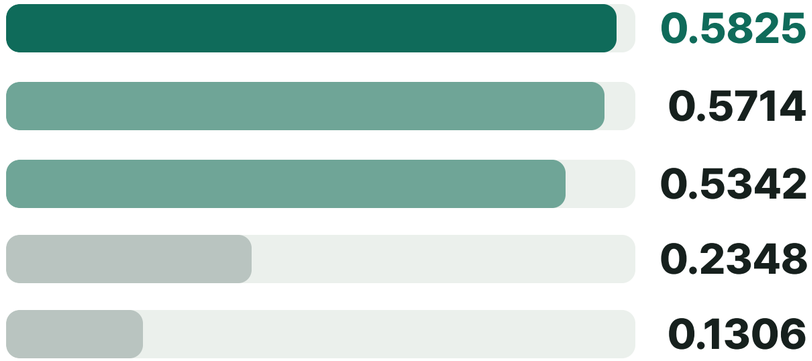


과거로 학습해 다음 시기를 맞힘 → **현장 배포 조건**에 가장 가까움

6 모델 실험 · 비교

같은 시험에서 KNN 0.5825 — RF와 비슷하고, MLP · 로지스틱보다 높다

macro F1 · train을 5묶음으로 나눠 돌아가며 시험 → 모든 샷을 한 번씩 검증



모델	불량 1,182건 중 잡음	정상 4,092건 중 헛경보
KNN	**600** (50.8%)	**120**
RandomForest	598 (50.6%)	124
로지스틱 (가중치)	1,128 (95.4%)	3,147
로지스틱	5 (0.4%)	10

주요 개선 실험 — 모두 최종에서 제외

불량 샘플 늘리기 (SMOTE · 노이즈)
탐지율 48% → 62%, macro F1 −0.010 ~ −0.023

정상 확률 낮춰 불량 쪽으로 판정
배율 0.9 ~ 0.4 모두 하락 → 1.0 유지

클래스 가중치 앙상블
처음 0.58 → 중첩 검증으로 다시 재니 0.546

KNN + RF + XGB 앙상블 · 제품별 모델
+0.0023 · −0.0008 → 기준 미달 (다음 장)

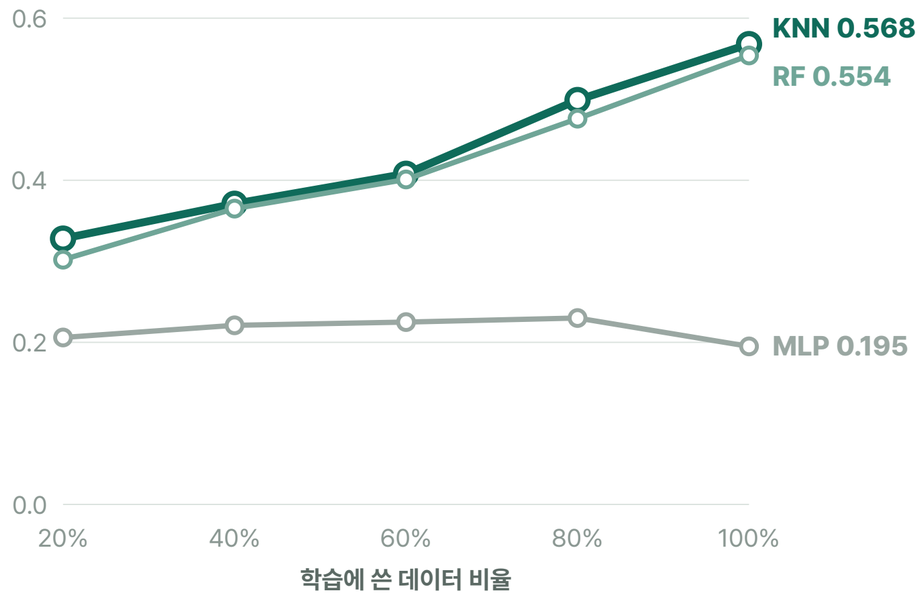
변수 51개 조합 · 세부 라벨 학습
−0.006 · 전부 하락

불량을 더 '의심'하게 하면 헛경보가 더 빨리 늘어 **macro F1은 오르지 않았다**

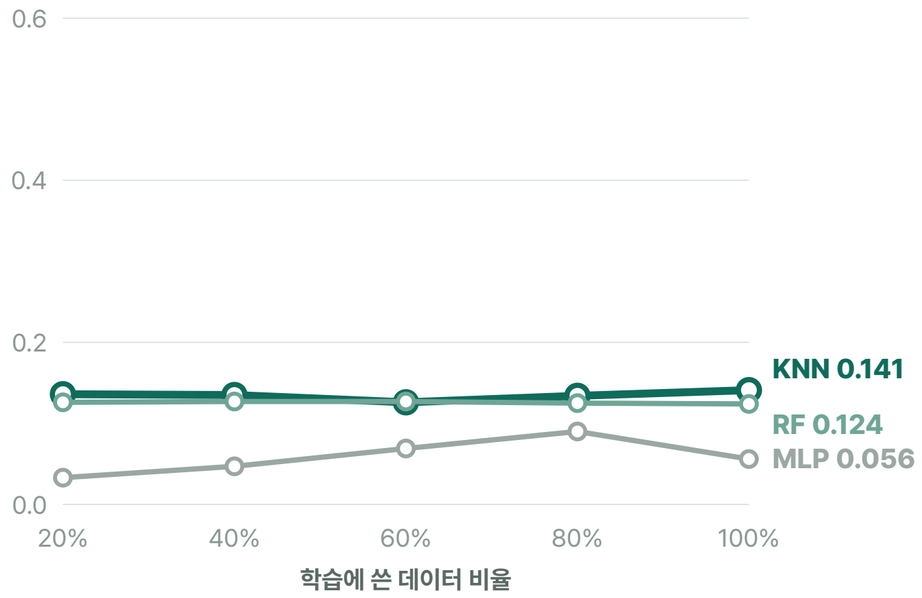
6 모델 실험 · 데이터 양

데이터를 늘리면 무작위에선 오르지만 — 시간순에선 어떤 모델도 그대로

무작위로 나눔 (학습 80 : 시험 20) · 리더보드와 비슷한 조건



시간순으로 나눔 (앞 80 → 뒤 20) · 처음 보는 시기

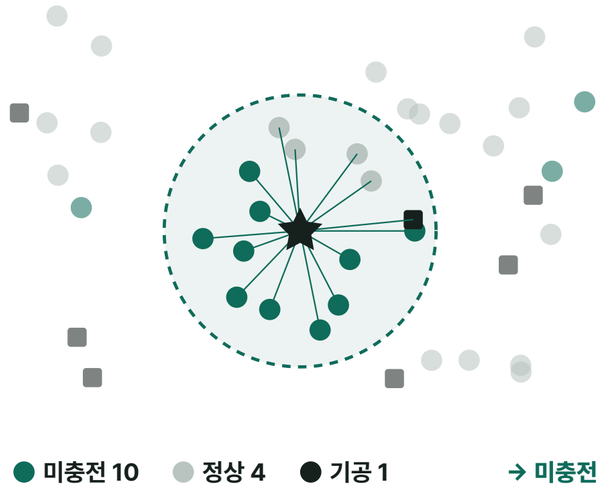


macro F1 · 검증 20% 고정, 학습 데이터 20% → 100% (100% 외에는 3번 반복 평균) · MLP는 작은 MLP(64-32)

7 최종 모델 선택 이유 1

KNN의 특징이 이 데이터의 구조와 맞았다

KNN · 가장 비슷한 과거 샷 15개로 판정 (그림은 예시)



21개 값을 같은 눈금(0~1)으로 맞추고 → 값 차이가 가장 작은 과거 샷 **15개** → 가까울수록 더 큰 표

KNN의 특징	이 데이터에서는	근거
1 비슷한 과거 샷을 그대로 찾아온다	21개 값이 같은 중복 기록이 **58.7%**	같은 기록이 있는 샷 macro F1 **0.831**
2 경계 모양을 가정하지 않고 주변만 본다	불량은 조건이 겹친 **좁은 구간**에 몰림	직선 경계 로지스틱 0.1306 → KNN **0.5825**
3 조건이 다르면 거리가 멀다	제품 1 · 2는 주조압 1,052 vs 596	이웃 중 다른 제품 **0.0%** → 제품별 모델 불필요 (−0.0008)
4 설정이 3개뿐 · 판정 근거가 보인다	이웃 수 · 거리 재는 법 · 가까울수록 가중	84개 설정 중 **1등**, 이웃 수 11~21이면 차이 < 0.01, 나누는 방법을 21번 바꿔도 0.5466 ~ 0.5825
! 같은 기록이 없으면 약하다	처음 보는 샷 · 다른 시기	같은 기록 없는 샷 **0.269** → 한계 (9장)

7 최종 모델 선택 이유 2

'확실히 이김' 기준을 넘은 대안이 없었다 → 가장 단순한 KNN 유지

KNN과 같은 시험 세트 15개로 짝지어 비교

읽는 법 점 하나 = KNN 대신 써 볼 대안. **오른쪽 위 초록 칸**(평균 +0.01 이상 · 15번 중 12번 이상 승리)에 들어와야 KNN을 바꾼다 → **4개 모두 칸 밖**



채택 기준 (먼저 정함)

평균 +0.01 이상 그리고
15번 중 12번 이상 승리

시험 세트 하나만 바뀌어도 점수가 ±0.03 흔들림 → 이보다 작은 차이는 운과 구분 불가

결과

KNN+RF+XGB 앙상블 **+0.0023** · 11/15	미달
파생 변수 4개 추가 **+0.0035** · 10/15	미달
제품별 KNN **−0.0008** · 4/15	미달
RF (가장 나은 설정) **−0.007** · 6/15	미달

결과적으로 public 7번 제출 중에서도 **KNN이 최고 (0.5890)** — 선택은 public이 아니라 검증으로 했다

8 최종 모델 상세 평가

종류는 잘 가리지만 — 놓친 582건은 전부 '정상'으로 판정했다

혼동행렬 · 가로줄 = 실제, 세로줄 = 모델 판정 (train 5,274샷, 5번 나눠 시험)

읽는 법 ■ 대각선 = 맞힘 · ■ 첫 세로줄 = 불량인데 **정상으로 놓침** · ■ 나머지 = 다른 불량으로 착각

실제 \ 예측	Normal 정상	Short_Shot 미충전	Blow_Hole 기공	Exfoliation 박리	Stain 얼룩	Deformation 변형	기타불량 기타
Normal 정상	3,972	45	23	23	6	18	5
Short_Shot 미충전	215	240	2	8	2	1	1
Blow_Hole 기공	87	2	144	0	0	0	0
Exfoliation 박리	112	4	0	75	0	6	1
Stain 얼룩	25	6	0	0	69	0	0
Deformation 변형	78	0	0	2	0	26	0
기타불량 기타	65	1	0	0	0	0	10

↑ 놓침 582 대각선 맞힘 564 · 다른 불량으로 착각 36

색이 진할수록 그 실제 유형 중 비율이 높음

클래스별 정밀도 · 재현율 · F1

유형	정밀도	재현율	F1
Normal 정상	0.87	0.97	0.92
Short_Shot 미충전	0.81	0.51	0.63
Blow_Hole 기공	0.85	0.62	0.72
Exfoliation 박리	0.69	0.38	0.49
Stain 얼룩	0.90	0.69	0.78
Deformation 변형	0.51	0.25	0.33
기타불량 기타	0.59	0.13	0.22
macro 평균			**0.5825**

왜 변형 · 기타불량이 약한가 · 학습 쪽에 같은 기록이 있는 비율

다른 불량 **41 ~ 61%** vs 변형 **9%** · 기타불량 **17%**

같은 기록이 없으면 어떤 불량도 5 ~ 22%만 맞힘

8 특징 중요도

모델은 공장 공기 상태와 고속 사출 속도를 가장 많이 봤다

중요도 상위 10개 — 공장 공기 상태 · 설비 · 공정 설정



꼭 같이 볼 단서

중요하다 = 예측에 쓸모 있었다

원인이라는 뜻은 아니다

원인인지는 조건을 하나만 바꾼 시험 생산으로 확인 (10장)

현장 숫자로 보면

건조도 중앙값

변형 **12.5** · 기타불량 **11.9** vs 정상 **7.9**

→ 덥고 건조한 날 변형이 많이 관찰됨

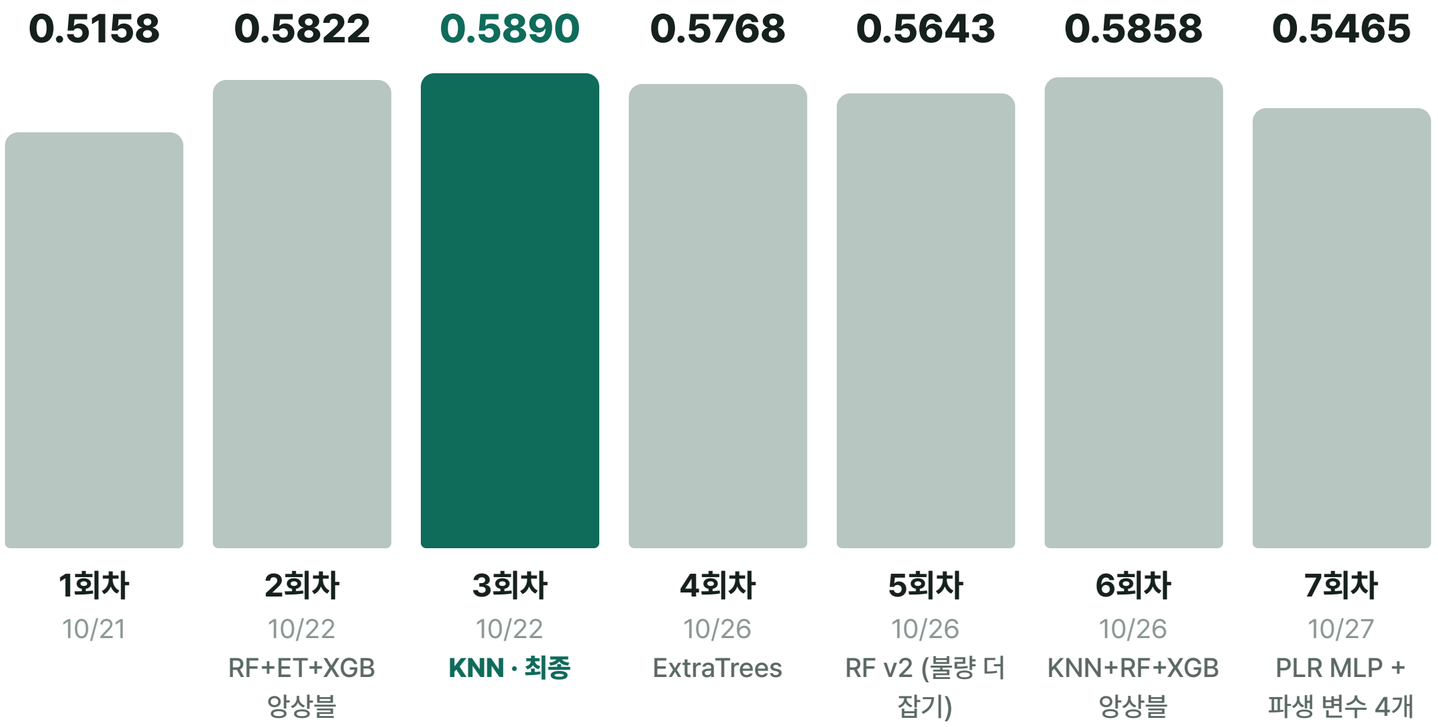
어떤 모델의 중요도인가

KNN은 중요도를 따로 내지 않아, 파생 변수 4개를 더한 **랜덤포레스트(300그루)**로 확인

9 최종 결과

public 0.5890 — 7번 제출 중 최고, 최종 제출은 3회차 KNN

public macro F1 · 제출 7회 (리더보드 통보값)



최종 제출

0.5890

정확도 86.9% · 불량 탐지율 56.1%
train 5,274샷 전체로 학습 → 2,261샷 예측
python main.py로 다시 실행해 차이 0샷

이 점수의 조건

test의 **57.7%**가 train에 같은 기록

→ 무작위 검증 0.570과 비슷한 조건
private은 아직 채점 전

9 한계

처음 보는 시기에는 불량 10개 중 2개만 잡는다 — 이것이 현장 성능에 가깝다

무작위로 나눔 · 리더보드와 비슷

53%

불량 237건 중 126건

macro F1 0.570 · 헛경보 27건

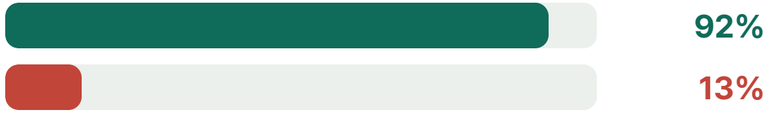
시간순으로 나눔 · 처음 보는 시기

19%

불량 231건 중 45건

macro F1 0.138 · 헛경보 155건

왜 차이가 나나 — 학습 쪽에 같은 기록이 있느냐



불량 탐지율 · 563건 중 517건 vs 619건 중 83건

한계

처음 보는 샷에 약하다

지금 21개 값으로는 같은 기록이 없는 샷의 불량을 가르기 어렵다

같은 기록을 더 모아도 그대로

학습 데이터 20% → 100%에서 시간순 0.136 → 0.141

설정을 같은 train으로 골랐다

교차검증 점수가 약간 낙관적일 수 있다

시간순 검증 구간엔 3종류뿐

변형은 생산 초반, 얼룩은 한 구간에만 있음

10 활용 방안

지금은 검사를 대신할 수 없다 → 검사는 그대로, 순서만 모델로

하루 비용 · 처음 보는 시기 기준, 하루 1,000샷 (불량 219샷)



비용 = 놓침 × 10 + 헛경보 × 1 (1 = 정상품 1개 재검사, 10 : 1은 가정) · 배율 = 정상 확률에 곱하는 값, 낮을수록 경보 많음 · 전수 검사는 검사가 불량을 다 잡는다는 가정

지금 쓰면 (배율 1.0)

하루 1,000샷에 경보 약 **190건**,
그중 실제 불량 약 **43건**

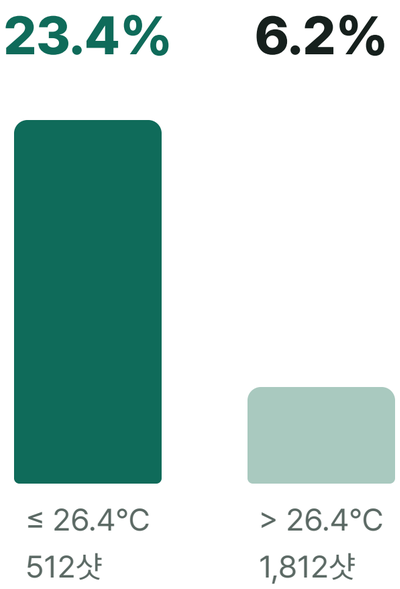
제안 · 몇 주 시범 운영

1. 지금 검사는 줄이지 않고 그대로
2. 모델이 의심한 샷을 **먼저** 검사
3. 의심 샷 중 실제 불량 수 · 표시 없이 지나간 불량 수를 센다
4. 현장이 정한 비용 비율 · 하루 검사 가능 수량으로 계속 쓸지, 배율을 얼마로 할지 결정

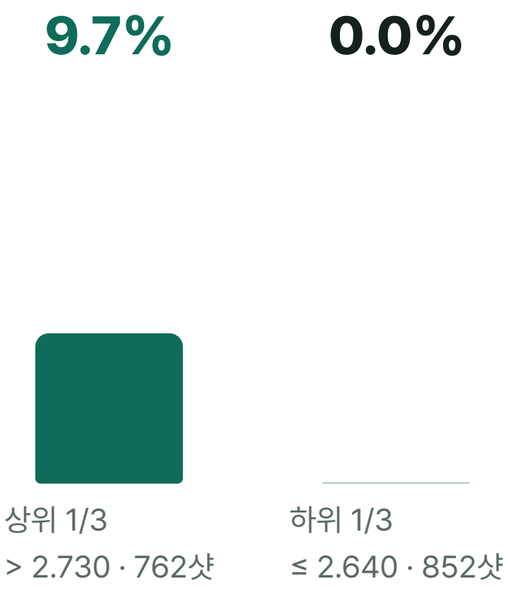
10 활용 방안 · 공정 조건

불량이 몰리는 조건 — 냉각수 26.4°C 이하에서 기공이 4배

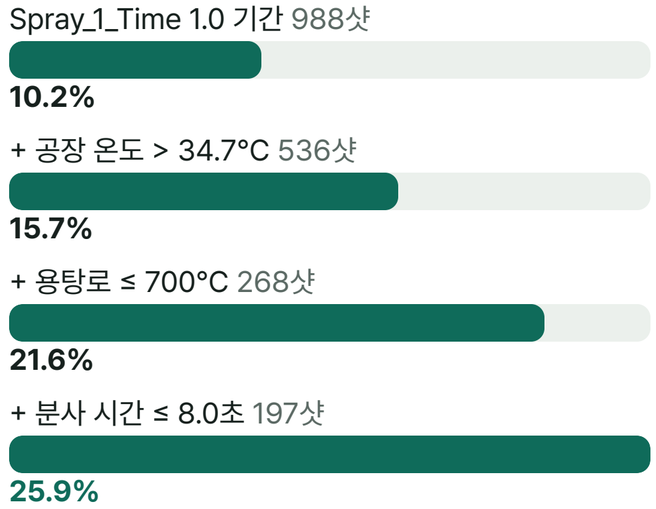
Blow_Hole (기공) · 제품 2 · 냉각수 온도



Stain (얼룩) · 제품 2 · 냉각수 압력



Deformation (변형) · 제품 1 · 조건 겹치기

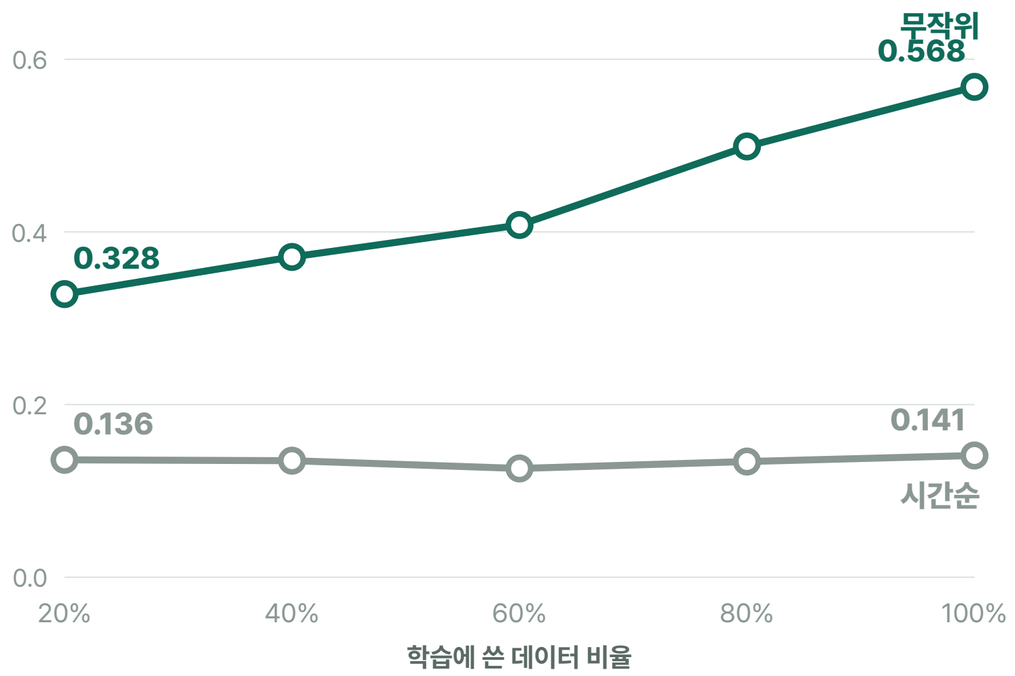


주의 관련성이지 원인 확인이 아니다 — 조건과 생산 시기가 겹친다. 한 조건만 바꾼 통제 시험 생산으로 확인해야 한다 (train 기준, 중복 기록도 각각 한 샷으로 셈)

10 개선 방향

같은 기록을 더 모으기보다 — 지금 안 재는 값을 새로 재야 한다

학습 데이터 양을 늘리면 · KNN macro F1 (검증 20% 고정)



무작위에서 오르는 것은 검증 샷의 같은 기록이 학습 쪽에 들어갈 확률이 함께 늘어난 영향이 섞인 것으로 추정

1 이슬점 · 건조도만 따로 넣어 재확인

변형 · 기타불량은 건조도 중앙값 12.5 · 11.9 vs 정상 7.9. 4개를 함께 넣은 RF는 중복 기록 묶기에서 +0.019 (15번 중 13번) → **시간순 기준**으로 다시 확인

2 데이터 추가 — 양보다 종류

금형 온도 등 지금 없는 측정값, 설정을 바꾼 **다른 생산 시기**의 기록

3 통제 시험 생산

같은 날 냉각수 온도만 **26°C / 27°C**로 나눠 기공 비율 비교 · 변형도 Spray_1_Time 1.0에서 용탕로 온도 · 분사 시간을 하나씩 바꿔 확인

+ AI를 어떻게 썼나

AI 조언 11건 중 2건만 채택 — 틀린 계산 3건은 결과를 직접 열어 찾았다

Claude(Claude Code)로 코드 작성 · 실험 설계 · 결과 요약 → 조언마다 같은 시험으로 다시 재서 판정 (기준: 평균 +0.01 이상 · 대부분 승리)

채택 2	기각 6 · 이 데이터에선 효과 없음	AI 오류 발견 3

오류 발견

시간순 점수 0.246

3개 유형만으로 평균한 값 → 7개 기준으로 다시 계산하니 **0.138**

오류 발견

가중치 적용 0.58

가중치를 고른 데이터로 그대로 채점한 값 → 중첩 검증으로 다시 재니 **0.546**

채택

같은 기록끼리 묶어 시험

무작위 0.562 vs 묶기 **0.268** → 리더보드 점수의 큰 부분이 중복 기록 덕분임을 확인

기각 예: 불량 샘플 늘리기(SMOTE) −0.010 ~ −0.023 · 판정 기준 옮기기 모두 하락 · 변수 51개 조합 −0.006 · 그 밖의 오류: MLP 조기 종료 구간을 잘못 뗀 코드

Q & A

리더보드 0.589는 '이미 본 샷' 조건 · 현장에서는 검사 순서를 돕는 보조 도구로 시작

3조 · 강동하 · 구정희 · 이지수 · 이창우